

# Un algoritmo de dos fases para reconocer las actividades humanas en el contexto de la Industria 4.0 y procesos impulsados por humanos

5 de octubre de 2022

## Resumen

Los futuros sistemas industriales, una revolución conocida como Industria 4.0, son imaginaciones para integrar a la gente dentro del mundo cibernético como consumidores (servicio de proveedores y consumidores). En este contexto, los procesos impulsados por humanos aparecen como una realidad esencial e instrumentos para crear bucles de información de retroalimentación entre el subsistema social (gente) y el subsistema cibernético (componentes tecnológicos) son requeridos. Aunque muchos instrumentos diferentes han sido propuestos, hoy en día las técnicas de reconocimiento de patrones son lo más prometedoras. De todos modos, estas soluciones presentan algunos problemas importantes pendientes. Por ejemplo, ellos son dependientes en la selección de herramientas para adquirir la información de los usuarios; o presentan un límite en la precisión para el reconocimiento del proceso. Para dirigir esta situación, en este papel es propuesto el algoritmo de dos fases para integrar personas en los sistemas Industria 4.0 y los procesos impulsados por el hombre. El algoritmo define acciones complejas como composiciones de movimientos simples. Las acciones complejas son reconocidas usando el modelo oculto de Markov, y simples movimientos son reconocidos usando la Deformación Dinámica del Tiempo. En este camino solo los movimientos dependen de las herramientas empleadas para capturar información en los dispositivos, y la precisión de acciones complejas su reconocimiento aumenta considerablemente. Un experimento real validado es también llevado fuera para evaluar y comparar el rendimiento para proponer la solución.

Industria 4.0; reconocimiento de patrones; Deformación Dinámica del Tiempo; Inteligencia artificial; Modelos Ocultos de Markov.

## 1. Introducción

Industria 4.0 [1] se refiere al uso de Sistemas Cibernéticos (unión de lo físico y los sistemas cibernéticos) [2] un principal componente tecnológico en el futuro de soluciones digitales, principalmente (pero no solo) en escenarios industriales. Típico, la digitalización ha causado, al final, el reemplazamiento de los mecanismos tradicionales por nuevos instrumentos digitales. Por ejemplo, trabajadores en líneas de montaje han sido sustituidos por robots durante la tercera revolución industrial. Sin embargo, algunas aplicaciones industriales no pueden basarse en soluciones tecnológicas, siendo el trabajo humano esencial [3]. Los productos elaborados a mano son un ejemplo de aplicaciones donde la presencia del humano es esencial. Este sector de las industrias, en cualquier caso, podrían integrarse en la cuarta revolución industrial. Desde la unión de los sistemas cibernéticos (CPS) y la acción humana como servicio de proveedores (trabajos activos), surge la humanización CPS [4]. En estos nuevos sistemas, procesos impulsados por humanos son permitidos [5]; i.e. procesos que son conocidos, ejecutados y administrados por personas (a pesar de que ellos puedan ser vigilados por mecanismos digitalizados). Para crear una integración real entre personas y la tecnología, y mover el proceso de ejecución desde los subsistemas sociales (humanos) para el mundo cibernético (herramientas y componentes de software), técnicas para extraer información que necesitan. Muchas soluciones diferentes y enfoques han sido reportadas durante los últimos años, pero hoy en día las técnicas de reconocimiento de patrones son las más prometedoras. El uso de la inteligencia artificial, modelos estadísticos y otros instrumentos similares han permitido un real e increíble desarrollo de soluciones de reconocimiento de patrones, pero algunos cambios están pendientes. Primero, las técnicas de reconocimiento de patrones son dependientes de las herramientas fundamentales de los dispositivos para capturar información. La estructura y cambios en el proceso de aprendizaje si (por ejemplo) en lugar de acelerómetros consideramos sensores


infrarrojos. Esto es muy problemático como herramientas tecnológicas evolucionando mucho más rápido que soluciones de software. Y, segundo, esto es un límite para la precisión en los procesos de reconocimiento. De hecho, como las acciones humanas se vuelven más complicadas, más variables y modelos más complejos son requeridos para reconocerlos. Este enfoque genera una larga optimización de los problemas cuyo error residual es mayor a medida que aumenta el número de variables; que causan una disminución en la tasa de reconocimiento de éxito[6]. En conclusión, matemáticos (no software, por lo tanto, no dependían en la implementación) fuerzan una cierta precisión para los procesos de reconocimiento de patrones debido a las acciones que deben estudiar. Para evitar esta situación, un número muy pequeño de variables debe ser considerado, pero esto sólo reduce la complejidad para las acciones que pueden ser analizadas; una solución que no es aceptada en escenarios industriales donde son desarrolladas actividades de producción complejas. Por lo tanto, el objetivo de este papel es describir un nuevo reconocimiento de patrones, algoritmo que aborda estos dos problemas básicos. El mecanismo propuesto define acciones como una composición para movimientos simples. Los movimientos simples son reconocidos usando técnicas como la Deformación Dinámica del Tiempo (DTW). Este proceso es dependiente en la selección de herramientas para capturar información; pero DTW son muy flexibles y actualizan el repositorio de patrones para reconfigurar el algoritmo entero. Luego, las acciones complejas son reconocidas como combinaciones de movimientos simples mediante los Modelos Ocultos de Markov (HMM) [8]. Estos modelos son totalmente independientes de tecnologías de hardware, como ellos solo consideran las acciones simples. Estas dos fases también aproximan la complejidad de los modelos, incrementando la precisión y la tasa de éxito en el proceso de reconocimiento. El resto del papel es organizado como seguidores: La sección 2 describe el estado del arte en patrones de reconocimiento para actividades humanas; La sección 3 describe la solución propuesta, incluyendo las dos fases definidas; La sección 4 presenta como validación experimental usando un escenario real y usuarios; y la sección 5 concluye el papel.

## 2. Estado del arte en el reconocimiento de patrones.

Muchas de las diferentes técnicas de reconocimiento de patrones dirigidas a las actividades humanas han sido comunicadas. Sin embargo, las propuestas mas comunes han sido clasificadas en cinco categorías básicas [9]: (i) Modelos ocultos de Markov; (ii) el campo aleatorio condicional de la cadena de saltar; (iii) los patrones emergentes; (iv) el campo aleatorio condicional; y (v) los clasificadores bayesianos.

De hecho, la mayoría de los autores proponen el uso de los Modelos Ocultos de Markov (HMM) para modelar las actividades humanas. Los HMM permite modelar acciones como cadenas de Markov [10][11]. Básicamente, estos generan estados ocultos a partir de datos observables. En particular, el objetivo final de esta técnica es construir la secuencia de estados ocultos que se ajuste a una determinada secuencia de datos. Para finalmente definir todo el modelo, estos deben deducir de los datos los parámetros del modelo de forma fiable. La Figura 1 muestra una representación esquemática de como funcionan los Modelos Ocultos de Markov. Cuando se reconocen las actividades humanas, las acciones que componen las actividades son los estados ocultos, y las salidas de los sensores son datos en estudio. Los HMM, además, permiten el uso de técnicas de entrenamiento considerando el conocimiento previo sobre el modelo. Este entrenamiento es a veces esencial para «inducir» todas las posibles secuencias de datos requeridas para calcular los HMM. Por último, es muy importante tener en cuenta que los HMM simples e aislados pueden combinarse para crear modelos mas grandes y complejos.

Los HMM, sin embargo, son inútiles para modelar ciertas actividades simultáneas, por lo que otros autores han reportado una nueva técnica llamada Campo Condicional Aleatorio (CRF). Los FCI se emplean para modelar aquellas actividades que presentan acciones simultáneas o, en general, múltiples acciones interactivas [12][13]. Además, los HMM requieren un gran esfuerzo en el entrenamiento para descubrir todos los posibles estados ocultos. Para resolver estos problemas, el campo aleatorio condicional (CRF) emplea probabilidades condicionales en lugar de distribuciones de probabilidad conjunta. De esta manera, las actividades cuyas acciones se desarrollan en cualquier orden pueden modelarse fácilmente. A diferencia de las cadenas en los HMM, el CRF emplea gráficos acíclicos, y permite la integración de estados ocultos condicionales (estados que dependen de observaciones pasadas y/o futuras). Los CRF, por otro lado, siguen siendo inútiles para modelar ciertos comportamientos, por lo que algunas propuestas generalizan este concepto y proponen el campo aleatorio condicional de la cadena de saltar (SCCRF). El SCCRF es una técnica de reconocimiento de patrones, mas general que el CRF, que permite modelar actividades que no son secuenciales de acciones en la naturaleza [14]. Esta técnica trata de capturar dependencias de largo



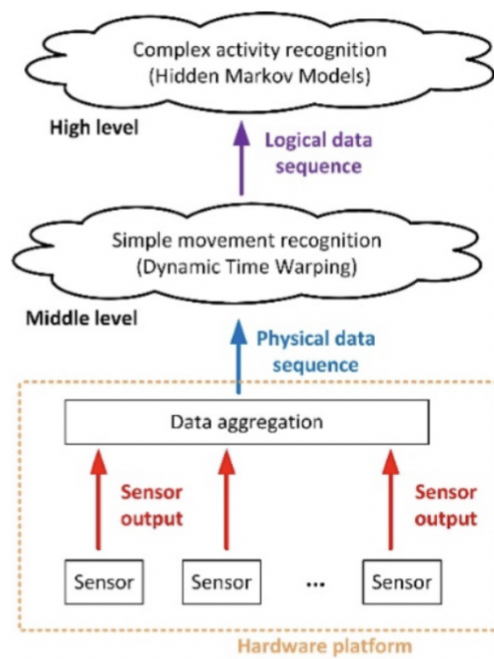
**Fig. 1.** Graphical representation of an HMM

alcance (saltar cadenas); y puede entenderse como el producto de diferentes cadenas lineales. Sin embargo, el calculo de es bastante pesada y complicada, por lo que esta tecnica suele ser demasiado costosa para ser implementada en pequenos sistemas embebidos.

Otras propuestas emplean tecnicas de descripcion de mayor nivel, como los Patrones Emergentes (EP). Para la mayoria de los autores, los EP es una tecnica que describe actividades como vectores de parametros y sus valores correspondientes (localizacion, objeto, etc. ) [15]. Utilizando distancias entre vectores es posible calcular y reconocer acciones desarrolladas por las personas. Por ultimo, otros autores han utilizado con exito tecnicas secundarias como los clasificadores bayesianos [16], que identifican actividades que corresponden entre las actividades humanas y las salidas mas probables de los sensores mientras se realizan estas acciones, considerando que todos los sensores son independientes. Arboles de decision [17], extensiones de los HMM [18] y otras tecnologias similares tambien han sido estudiadas en la literatura, aunque estas propuestas son escasas. De todas las tecnologias descritas, los HMM no es la mas potente. Sin embargo, encaja perfectamente con la Industria 4. 0, donde las acciones son muy complejas pero muy estructuradas y ordenadas (segun protocolos de la empresa, politicas de eficiencia, etc. ). Ademias, se requiere una retroalimentacion rapida (a veces incluso en tiempo real) para garantizar que los procesos impulsados por el hombre funcionen correctamente antes de que se produzca un fallo critico global. Por lo tanto, las soluciones computacionalmente costosas no son un enfoque valido, y estamos seleccionando HMM como tecnologia base principal. Para preservar su ligereza y, al mismo tiempo, poder modelar actividades complejas, introducimos un sistema de reconocimiento en dos fases que permite dividir acciones complejas en dos fases mas sencillas.

### 3. Un algoritmo de reconocimiento es dos fases.

Con el fin de (i) hacer que el proceso de reconocimiento de patrones sea independiente de los dispositivos de hardware empleados para captar informacion, (ii) permitir el reconocimiento de acciones complejas, y (iii) preservar el caracter ligero de los modelos seleccionados, la solucion propuesta presenta una arquitectura con tres capas diferentes (vease la figura2 .



**Figura 2.** Estructura de la solución propuesta del reconocimiento de patrones

La capa inferior incluye la plataforma hardware. Dispositivos de monitoreo como los acelerómetros, teléfonos móviles, sensores infrarrojos, etiquetas RFID, etc., están destinados a captar información sobre el comportamiento de las personas. Las salidas de estos dispositivos crean secuencias de datos físicos cuyo formato, rango dinámico, etc., son totalmente dependientes de las tecnologías hardware seleccionadas. Luego, estas secuencias de datos físicos son procesadas en la capa del medio empleando técnicas DTW. Como resultado, para cada secuencia de datos físicos, se reconoce un movimiento o una acción simple. Estas acciones simples se representan usando un formato de datos binario para hacer la solución lo menos pesada posible. En este nivel, el software debe modificarse cada vez que se actualiza la plataforma hardware, pero las tecnologías de DTW no requieren un proceso pesado de actualización, y es suficiente con actualizar el repositorio del patrón para configurar el algoritmo a este nivel. Una vez reconocidos los movimientos simples, estos son agrupados para crear una secuencia de datos lógica. Estas secuencias alimentan a un sistema de reconocimiento de patrones de alto nivel basado en los modelos ocultos de Markov. A este nivel, los componentes del software requieren un proceso de entrenamiento pesado, pero la capa del medio hace que la plataforma hardware y los modelos de alto nivel sean totalmente independientes. Por lo tanto, cualquier cambio en la plataforma hardware no obliga a una actualización en HMM (Modelos Ocultos de Markov), lo que sería extremadamente costoso computacionalmente. A través del análisis de la secuencia de movimientos simples, se reconocen acciones complejas. La próxima subsección describe ambas fases propuestas de reconocimiento de patrones en detalle.

### 3.1. Reconocimiento de movimientos simples: Deformación Dinámica del Tiempo (DTW)

Para poder reconocer movimientos o gestos simples, se selecciona una solución de deformación dinámica del tiempo. Las tecnologías DTW completan los requerimientos de los componentes de software de nivel medio, puesto que estos se adaptan fácilmente a las características de la plataforma hardware fundamental y son bastante rápidas y eficientes (por lo que los dispositivos pequeños integrados pueden implementarlos). En nuestra solución, el comportamiento humano es monitorizado a través de una familia de sensores  $\delta$ , conteniendo  $N_s$  componentes (1).

$$S = \{s_i, i = 1, \dots, N_s\} \quad (1)$$

Las salidas de estos sensores son muestreadas periódicamente cada  $T_s$  segundos; obteniendo por cada instante,  $t$ , un vector de  $N_s$  valores (cada valor de cada sensor). Este vector  $Y_s$  se denomina “una muestra multidimensional”. (2)

$$Y_t = \{y_t^i, i = 1, \dots, N_s\} \quad (2)$$

Entonces, un movimiento simple  $Y$  tendrá una duración  $T_m$  de segundos y será descrita por la secuencia temporal de  $N_m$  muestras multidimensionales recogidas durante este tiempo (3). Para poder reconocer movimientos más tarde, se crea un repositorio de patrones  $R$  que contiene las correspondientes secuencias para cada una de las  $K$  acciones simples a ser reconocidas (4).

$$Y = \{Y_t, t = 1, \dots, T_m\} = \{Y^i, i = 1, \dots, N_m\} \quad (3)$$

$$R = \{R_i, i = 1, \dots, K\} \quad (4)$$

En general, la gente realiza movimientos con un comportamiento similar pero diferente. Así, las transiciones pueden ser más lentas o rápidas, algunas acciones elementales pueden ser añadidas o eliminadas, etc. Por lo tanto, dada una secuencia  $X$  con  $N_x$  muestras, representando un movimiento a ser reconocido, este debe estar en el patrón  $R_i \in R$  más cercano a  $X$ ; por lo que  $R_i$  es reconocido como una acción realizada. Para hacer eso se define la función distancia (5). Esta función de distancia puede aplicarse para calcular matriz de costos, requerida ya que las muestras normalmente no tienen la misma longitud ni están alineadas (6).

$$d : F \times F \rightarrow R^+, X^i, r_j^i \in F \quad (5)$$

$$C \in R^{(N_x) \times (N_m)} C(n, m) = d(X^n, R_j^m) \quad (6)$$

En sensores posicionales (acelerómetros, dispositivos de infrarrojos, etc.) la función de distancia se aplica directamente a las salidas de los sensores (de manera contraria a, por ejemplo, los micrófonos cuyas salidas deben de ser evaluadas en el dominio de poder). Aunque se puedan emplear otras

funciones de distancia (la divergencia de Kullback-Leibler o la distancia de Manhattan), para este primer trabajo vamos a usar la distancia estándar Euclídea (7).

$$d(X^n, R_j^m) = \sqrt{\sum_{N_s}^{i=1} (x_i^n - r_i^{m,j})^2} \quad (7)$$

Luego, se define un camino de deformación  $p = (p_1, p_2, \dots, p_L)$  como una secuencia de pares  $(n_l, m_l)$  con  $(n_l, m_l) \in [1, N_x] \times [1, N_m]$  y  $\ell \in [1, L]$ , satisfaciendo tres condiciones: (i) la condición de contorno, por ejemplo,  $p_1 = [1, 1]$  y  $p_L = [N_x, N_m]$ ; (ii) la condición de monotonicidad, por ejemplo,  $n_1 n_2 \dots n_L$  y  $m_1 m_2 \dots m_L$ ; y (iii) la condición de tamaño de paso, por ejemplo,  $(p_l p_{l-1}) \in (1, 0), (0, 1), (1, 1)$  con  $\ell \in [1, L]$ . Entonces, el coste total de un camino de deformación  $p_i$  es calculado añadiendo todos los costes parciales o distancias (8). Con todo esto, la distancia entre dos secuencias de datos  $R_i$  y  $X$  queda definida como el coste (distancia) del camino óptimo de deformación  $p^*(9)$ .

$$d_{pi}(X, R_j) = \sum_{\ell=1}^L d(X^{n_\ell}, R_j^{m_\ell})^2 \quad (8)$$

$$d_{DTW}(X, R_j) = d_p * (X, R_j) = \min(d_{pi}(X, R_j), \text{being } p_i \text{ a warping path}) \quad (9)$$

Finalmente, el movimiento simple reconocido a partir de la secuencia de datos  $X$  es aquel cuyo patrón  $R_i$  tiene la menor distancia (es el más cercano) con  $X$ . El uso de esta definición es tolerante a las variaciones de velocidad en la ejecución del movimiento, a la introducción de nuevos micro gestos, etc. Además, como se puede observar, cuando se implementa una tecnología de hardware distinta, es suficiente con actualizar el repositorio de patrones para reconfigurar completamente la solución de reconocimiento de patrones (puesto que no hay entrenamiento requerido).

### 3.2. Reconocimiento de acciones complejas: Modelos Ocultos de Markov

El mecanismo propuesto anteriormente es muy útil para reconocer acciones simples, pero las actividades complejas involucran un gran número de variables y requieren mucho más tiempo. De este modo, DTW tiende a ser impreciso, y se requieren modelos probabilísticos. Entre todos los modelos ya existentes, HMM es el más adecuado para escenarios industriales y procesos dirigidos por humanos. Desde la fase anterior, el universo de movimientos simples posibles a ser reconocidos es  $M = \{m_i, i = 1, \dots, K\}$ . Además, se define un universo estatal  $U = \{u_i, i = 1, \dots, Q\}$ , describiendo todos los estados que la gente pueda cruzar durante la realización de cualquiera de las acciones bajo estudio.

A (10) describe la probabilidad del estado  $u_j$  siguiendo el estado  $u_i$ ; (ii) la matriz de observación (11) Después, un conjunto de observaciones  $O = \{o_i, i = 1, \dots, Z_o\}$  (movimientos simples reconocidos en la fase anterior) es además considerado, así como la secuencia de estados  $V = \{v_i, i = 1, \dots, Z_o\}$  describiendo la acción modelada por HMM. En este caso inicial, asumimos que cada observación corresponde a un nuevo estado, así que  $Z_v = Z_o$ . Después, tres matrices son calculadas: (i) la matriz transitoria describe la probabilidad de la observación  $o_i$  causada por el estado  $u_j$  independientemente de  $k$ ; y (iii) la matriz de probabilidad inicial (12).

$$A = [a_{ij}] \quad a_{ij} = P(v_k = u_j | v_{k-1} = u_i) \quad (10)$$

$$B = [b_j(o_i)] \quad b_j(o_i) = P(x_k = o_i | v_k = u_j) \quad (11)$$

$$\prod \pi_i \quad \pi_i = P(v_1 = u_i) \quad (12)$$

Después, el HMM para cada actividad compleja  $\lambda_i$  a reconocer está descrito por estos tres elementos anteriores (13).

$$\lambda_i = \{A_i, B_j, \prod_i\} \quad (13)$$

Dos suposiciones son, además, hechas: (i) el supuesto de Markov (14) que muestra que cualquier estado solo depende del anterior; and (ii) la suposición de independencia (15) que establece que cualquier secuencia de observación depende solo del estado actual, no de estados u observaciones anteriores.

$$P(v_k | v_1, \dots, v_{k-1}) = P(v_k | v_{k-1}) \quad (14)$$

$$(o_k | o_1, \dots, o_{k-1}, v_1, \dots, v_k) = P(o_k | v_k) \quad (15)$$

Para evaluar el modelo y reconocer la actividad que realizan los usuarios, en esta hoja usaremos un enfoque tradicional (16). Aunque se ha demostrado que los algoritmos avanzados son más eficientes, para este trabajo inicial estamos implementando directamente la expresión de evaluación en su forma tradicional.

$$P(O|\lambda) = \sum_V P(O|V, \lambda) P(V|\lambda) =$$

$$= \sum_v (\prod_{i=1}^z (i=1)^{z_o}) P(o_i|v_i, \lambda) (\pi_v 1_{a_{v1}v2} \dots a_{v_{zv-1}v_{zv}}) =$$

$= \sum_v (v1, v2, \dots, v_z v) \pi_v 1_{a_{v1}v2} b_{v2}(o_2) \dots a_{v_{zv-1}v_{zv}} b_{v_{zv}}(o_{zo})$  (16) El proceso de aprendizaje también se implementó de la manera más sencilla. Se emplearon definiciones estadísticas para la matriz transitoria, la matriz de observación y la matriz de probabilidad inicial. En particular, la definición de Laplace de probabilidad era empleada para estimar estas tres matrices a partir de estadísticas sobre actividades bajo estudio (17-19). El recuento de operadores  $()$  indica el número de veces que un evento ocurre.

$$a_{i,j} = P(u_j|u_i) = \frac{\text{count}(u_j \text{ follows } u_i)}{\text{count}(u_j)} \quad (17)$$

$$b_j(o_i) = P(o_i u_j) = \frac{\text{count}(o_i \text{ is observed in the state } u_j)}{\text{count}(u_j)} \quad (18)$$

$$\pi_i = P(v_1 = u_i) = \frac{\text{count}(v_1 = u_i)}{\text{count}(v_1)} \quad (19)$$

## 4. Validación experimental: implementación y resultados

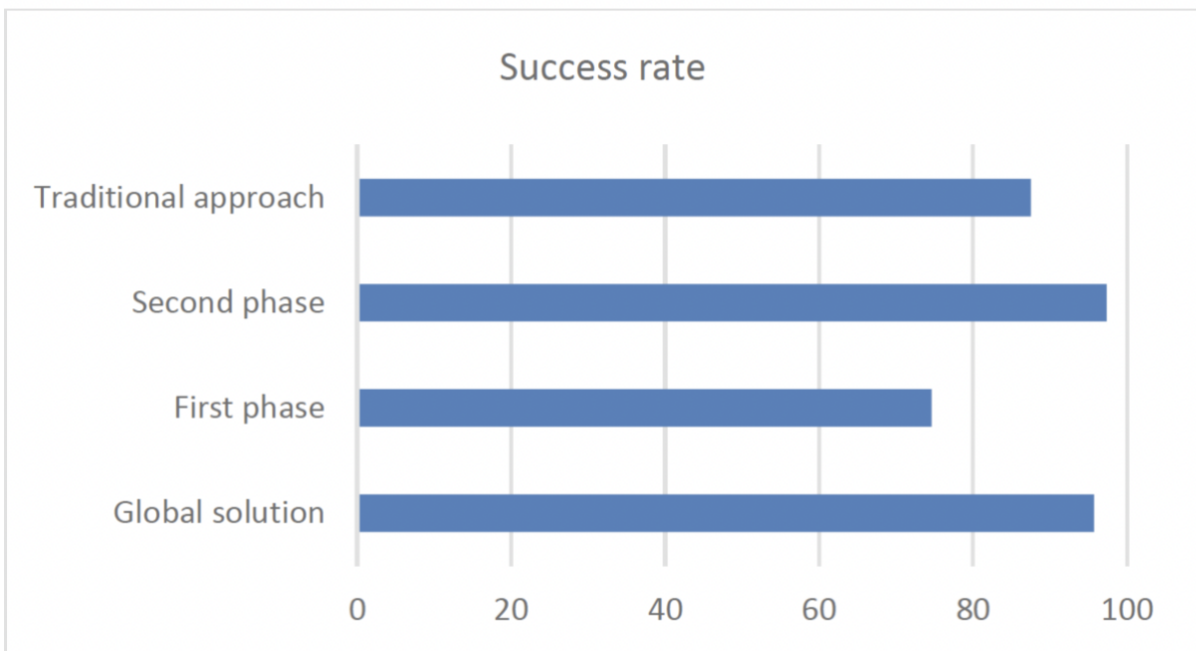
Con el fin de evaluar el rendimiento de la solución propuesta, se diseñó una validación experimental y se llevó a cabo. Se emitió un escenario industrial en algunas habitaciones de la Universidad Politécnica de Madrid. El escenario representaba una compañía tradicional que manufacturaba productos hechos a mano. En particular, una pequeña PCB (talones de circuitos impresos) manufacturada fue emulada. Con el fin de capturar información sobre el comportamiento de la gente, se le proporcionó a los participantes un guante cibernético, incluyendo acelerómetros y lectores RFID[19]. Los objetos alrededor de los escenarios eran identificados con un RFID, por lo que la plataforma de hardware propuesta puede identificar la posición de la mano(gesto) y los objetos con los que las personas interactúan. Una lista de doce actividades diferentes complejas fue definida y reconocida usando la tecnología propuesta. La tabla 1 describe las doce actividades propuestas, incluida una breve descripción de ellas.

Dieciocho personas participaron en el experimento. Se le pidió a la gente que realizara las actividades de forma aleatoria. El orden real, así como el orden por el que se reconocían las actividades era almacenado por un proceso de supervisión de software. La tasa global del proceso fue evaluada, identificando (además), la misma tasa para cada una de las fases existentes.

Con el fin de evaluar la mejora obtenida en comparación con las soluciones similares existentes, las mismas secuencias de datos se usaron para alimentar una solución estándar de reconocimiento de patrones basada solo en HMM. Usando un software de procesamiento de datos estadísticos, se extrajeron algunos datos relevantes. La figura 4 representa la tasa media de éxito para tres casos: la solución global, la primera fase (DTW), y la segunda fase (HMM). Además, la tasa de éxito para el enfoque tradicional basado en HMM está también incluida. Como se puede ver, la tecnología propuesta es, mundialmente, alrededor de un 9 % mejor que las técnicas tradicionales basadas en HMM exclusivamente. Además, la primera fase (basada en DTW) es alrededor de un 20 % peor que la segunda fase (HMM) ya que significativamente las técnicas Dynamic Time Warping son peores por defecto.

**Tabla 1.** Descripciones de actividades complejas

Actividad	Descripción
Dibuja los caminos del circuito	El circuito que se va a imprimir está diseñado utilizando un programa de PC de software específico.
Imprime el diseño del circuito con un plotter	Utilizando una hoja de plástico y una impresora especial llamada plotter, se imprime el diseño del circuito.
Limpiar el laminado de cobre de las tablas	Con un producto especial, se eliminan todo el polvo y las partículas del laminado de cobre.
Copiar el diseño del circuito en las placas de tonel	El diseño del circuito en la lámina de plástico se copia en el laminado del tonel utilizando una explosión de luz UV.
Sumergir las tablas en la piscina de ácido	Para eliminar todas las esperanzas no deseadas, el tablero impreso se sumerge en un baño de ácido.
Lavar el tonel con un baño disolvente	Después del baño ácido la superficie restante del tonel se lava en un baño disolvente.
Alinear las capas	Los PCB están compuestos por varias capas; apilados y alineados durante esta fase.
Inspección óptica	Con un láser, se comprueba la alineación de la capa.
Unir las capas externas con el sustrato	Con un pegamento epoxi, se unen la capa final y exterior de la capa.
Enlazar el tablero	La unión se realiza en una mesa de acero pesado con abrazaderas metálicas.
Perforar los agujeros necesarios	Los agujeros para los componentes, etc., se perforan en el tablero de la pila.
Revestir	En un horno, la tabla está terminada.



**Fig 4.** Tasa media de éxito de la solución propuesta



## 5. Conclusiones y futuros trabajos.

En esta hoja presentamos un nuevo algoritmo de reconocimiento de patrones para integrar gente en la Industria 4.0 y los procesos conducidos por el hombre. El algoritmo define actividades complejas como composiciones de simples movimientos. Las actividades complejas son reconocidas usando Hidden Markov Models, y los movimientos simples son reconocidos usando Dynamic Time Warping. Para permitir la implementación de este algoritmo en pequeños dispositivos integrados, se seleccionan configuraciones ligeras. Una validación experimental también se lleva a cabo, y los resultados muestran una mejora global de alrededor del 9

Los futuros trabajos considerarán metodologías más complejas para el procesamiento de datos, y se evaluará la comparación para las diferentes configuraciones del algoritmo propuesto. Además, la propuesta se analizará en diferentes escenarios.

En conclusión, este experimento ha servido para comprobar que técnicas como los HMM sirven para generar estados ocultos a partir de datos observables en la Industria 4.0. Como hemos leído anteriormente, esta técnica no es la más potente, de hecho cuando hablamos de resolver problemas que requieran un gran esfuerzo en el entrenamiento para descubrir todos los estados ocultos, usamos el campo aleatorio condicional. Pero a pesar de esto, es la que mejor encaja en la Industria 4.0. En el documento podemos encontrar una validación experimental, en la cual se han definido doce actividades complejas y se ha usado la tecnología propuesta. Nos presenta además una gráfica en la cual podemos ver el éxito de este experimento en tres casos: la solución global, la primera fase (DTW), y la segunda fase (HMM).